

方法背景与研究脉络

Yu等人的最终目的仍然是获得高精度、无歧义的绝对相位（absolute phase），从而完成可靠的三维重建，但其解决路径与传统时间相位展开方法完全不同。左超提出的时间相位展开方法和Yu提出的无训练深度学习方法，最终目标都是解决同一个问题，即从相机采集到的具有 2π 周期性的包裹相位 $\phi(x,y)$ 中恢复真实连续相位 $\Phi(x,y)$ ，进而建立投影条纹与物体空间点之间的对应关系，实现三维形貌恢复。左超等人的方法认为，相位歧义产生的根本原因是单幅包裹相位中缺少条纹级次信息，因此通过额外投影不同频率、不同波长的多幅条纹，引入时间维度编码信息，利用多频、多波长或数论方法确定每个像素对应的条纹级次 $k(x,y)$ ，最终通过 $\Phi(x,y)=\phi(x,y)+2\pi k(x,y)$ 获得绝对相位。也就是说，左超方法的核心思想是“增加测量数据，用额外时间信息消除相位不确定性”，其优势是理论成熟、稳定可靠，但代价是需要采集多幅图像，限制了高速动态测量能力。

Yu等人的创新则是在保持相同最终目标（恢复绝对相位）的基础上，尝试消除对多幅条纹编码的依赖，其提出的无训练深度学习相位恢复方法并不是简单利用大量数据训练一个“条纹到相位”的黑盒网络，而是在测量阶段利用网络自身优化能力，将结构光系统中的物理规律作为约束，使网络输出的相位满足真实三维成像条件。传统监督学习方法通常需要构建大量训练样本，即输入大量不同物体、不同表面条件下的条纹图像，同时需要对应的高质量绝对相位作为标签，通过CNN等网络学习映射关系：

$$I(x,y) \rightarrow \Phi(x,y)$$

例如训练数据通常由多步相移算法或Gray-code方法生成，将获得的高精度绝对相位作为ground truth，然后训练网络学习从少量条纹甚至单幅条纹直接预测相位。然而，这种方法存在明显局限：网络学习的是训练数据中的统计规律，当测试对象、材料反射特性、表面结构或测量环境与训练集存在差异时，容易产生泛化误差。此外，高质量相位标签获取成本较高，限制了实际应用。Yu方法针对这一问题提出“不依赖预训练数据”的思想，即网络参数不是提前学习得到，而是在当前测量对象上通过物理约束优化得到，使网络输出同时满足不同视角之间的相位一致性、图像结构一致性以及三维几何一致性，因此避免了传统监督学习对大规模标注数据的依赖。

因此，从研究发展角度看，左超等人代表的是传统结构光领域“通过增加编码信息提高相位展开可靠性”的发展路线，而Yu代表的是“利用物理先验和深度优化减少甚至消除额外编码需求”的新方向。二者虽然解决的是同一个最终问题——获得可靠绝对相位并完成三维重建，但左超关注的是如何利用更多观测信息解决相位歧义，Yu则进一步探索在观测信息极少（甚至单幅条纹）的情况下，如何借助物理约束恢复缺失的相位信息。因此，对于未来结构光条纹断裂修复研究，Yu的方法提供了更合适的思路：将条纹恢复、相位恢复和三维几何约束融合起来，不再单纯依赖完整条纹序列，而是利用结构光系统本身的物理规律恢复断裂区域的相位连续性。

ZeroTrain-FPP

ZeroTrain-FPP

面向单帧条纹投影三维测量的双目相位恢复研究。项目以 UDPR/UCNNet 为 baseline，探索**序数条纹级推断、有界相位残差和置信度物理约束**，目标是在不使用目标场景相位标签的条件下，提高绝对相位恢复的可靠性与效率。

当前状态：官方数据读取、标定解析、Baseline 官方输出评估和两阶段模型 骨架已经完成；完整物理损失、训练流程及消融实验仍在开发。README 中的“创新点”是待实验验证的研究假设，不代表已经取得性能提升。

项目概览

条纹投影轮廓术通过投影仪向物体表面投射正弦条纹，从相机采集图像中恢复 绝对相位，并进一步重建三维形貌。传统高精度方案通常需要多幅相移条纹和 Gray Code，不适用于高速运动场景；单帧方案采集速度快，但面临包裹相位误差 以及 2π 周期模糊。

本项目研究的问题是：

如何利用双相机之间的相位与几何关系，从左右单帧条纹中恢复可靠的绝对 相位，同时降低逐场景优化的计算成本？

推荐课题名称：

- 中文：基于序数条纹级推断与置信度物理约束的单帧双目相位恢复
- 英文：Confidence-Guided Stereo Phase Retrieval with Ordinal Fringe-Order Inference

方法

Baseline: UDPR/UCNNet

Baseline 来自论文 Untrained deep learning-based phase retrieval for fringe projection profilometry。它针对每个待测场景优化共享权重的双目 网络，不依赖当前场景的相位标签。

第一阶段根据左右单幅条纹 IL,IR 和 WFT 粗包裹相位 ϕ_{Lc}, ϕ_{Rc} 预测条纹级 KL,KR:

$$\Phi_i^c = \phi_i^c + 2\pi K_i.$$


第二阶段根据条纹和粗绝对相位 Φ_i^c 恢复精细绝对相位。优化过程 采用三种场景无关约束：

- 相位一致性：同一三维点在左右视图中对对应相同投影相位；
- 结构一致性：左右对应图像区域具有相似的局部结构；
- 三维一致性：双目系统与相机—投影仪系统给出的几何对应一致。

Baseline 局限

1. 条纹级本质上是离散、有序变量，但 Baseline 将其作为连续量回归，无法 显式描述候选条纹级的歧义；
2. 暗区、饱和区、遮挡区和弱纹理区可靠程度不同，固定损失权重容易受到错误 对应点干扰；
3. 每个场景从随机参数开始优化，计算成本较高；
4. 第二阶段直接处理大范围绝对相位，未充分利用“细化粗相位”的任务先验。

总体方案



拟验证的创新点

1. 序数概率条纹级推断

对候选条纹级建立概率分布：

$$p(k | I, \phi^c), \quad k \in [K_{\min}, K_{\max}],$$

并通过 soft-argmax 得到可微预测：

$$\hat{K} = \sum_k k p(k).$$

概率分布的归一化熵用于描述条纹级不确定度：

$$U_K = -\frac{1}{\log N} \sum_k p(k) \log p(k).$$

相较于无约束连续回归，该表示能够利用条纹级的离散和有序属性，并同时给出 预测值与可信程度。

2. 有界绝对相位残差

第二阶段只预测粗相位的周期内修正量：

$$\hat{\Phi} = \Phi^c + \Delta\Phi, \quad \Delta\Phi = \pi \tanh(z) \in [-\pi, \pi].$$

该设计缩小了网络输出空间，并通过物理边界减少异常的跨周期相位修正。

3. 置信度引导的物理约束

计划融合有效区域、曝光质量、局部纹理、条纹级熵和相位方差：

$$C = C_{\text{mask}} C_{\text{intensity}} C_{\text{texture}} C_{\text{order}} C_{\text{phase}},$$

并使用置信度加权的鲁棒损失：

$$\mathcal{L}_{\text{phy}} = \frac{\sum_x C(x) \rho(r(x))}{\sum_x C(x) + \epsilon}.$$

目标是降低遮挡、异常曝光和弱纹理像素对相位、结构及三维一致性优化的干扰。

4. 轻量测试时自适应

后续将探索共享初始化和低秩 Adapter：测试时冻结主干，只更新少量场景相关 参数，并根据物理残差提前停止。引入共享初始化后，方法应准确描述为 “无目标域标签的测试时自适应”，而不是“完全无训练”。

官方数据

本项目使用 Baseline 论文公开的约 7.5 GB 官方数据。数据不包含在 Git 仓库中，请将其放置在项目根目录的 Dataset/ 下。

数据部分	场景数	论文实验设置
section 3.2.1	100	充足、相似场景

数据部分	场景数	论文实验设置
section 3.2.2	15	有限场景
section 3.2.3	75	树皮、叶片等跨类别场景

每个公开场景包含左右单幅条纹、WFT 粗包裹相位、条纹级真值、粗绝对相位、绝对相位真值、有效 mask、官方两阶段输出以及系统标定参数。图像分辨率为 640×480。

公开文件共包含 190 个论文实验场景，并不是论文提到的全部 675 个采集场景。因此，数据划分和实验结论必须以实际公开文件为准。

预期目录结构：

```
Dataset/
├─ section 3.2.1/
│   ├── calibration parameter/
│   ├── fringe order range/
│   ├── data-stage1/
│   └── data-stage2/
├─ section 3.2.2/
└─ section 3.2.3/
```

已完成工作

- 兼容 classic MAT、MATLAB v7.3 与普通 HDF5；
- 将 MATLAB 保存的 640×480 数组恢复为 Python 的 [H,W]=[480,640]；
- 严格配对左右视图、两阶段输入、真值、mask 和官方输出；
- 解析相机—相机及相机—投影仪标定，并导出常规列向量/OpenCV 形式 K,R,t；
- 在有效 mask 内复算 MAE、RMSE、Bad-pixel rate 和条纹级准确率；
- 实现左右视图权重共享的两阶段网络；
- 实现 56 个候选条纹级、soft-argmax、熵不确定度、像素级候选范围和 $[-\pi,\pi]$ 相位残差。

核心文件：

文件	作用
fringe_repair/udpr_io.py	官方数据与标定解析
fringe_repair/udpr_metrics.py	Baseline 指标统计
fringe_repair/udpr_models.py	双目两阶段模型
scripts/evaluate_udpr_baseline.py	官方输出复现入口
tests/test_udpr.py	数据、标定和模型测试

Baseline 复现结果

以下结果由官方保存的 Stage-II 输出计算，而不是当前创新模型的训练结果：

数据部分	样本数	双视图 MAE	双视图 RMSE
section 3.2.1	100	0.1098 rad	0.3861 rad
section 3.2.2	15	0.0944 rad	0.3427 rad
section 3.2.3	75	0.0813 rad	0.2939 rad

结果与论文报告的约 0.10/0.08/0.07 rad 处于相同量级。差异可能来自 逐场景与逐像素平均方式、视图选择或未公开后处理，因此当前结论是“评估 链路正确且结果同量级”，不是“逐位复现论文数值”。

完整统计见 `results/udpr_official_baseline.json`。

快速开始

1. 安装

建议使用 Python 3.11 和 PyTorch 2.4 或更高版本：

```
git clone https://github.com/YeLuo-123/ZeroTrain-FPP.git
cd ZeroTrain-FPP

python3 -m venv .venv
.venv/bin/pip install --upgrade pip
.venv/bin/pip install torch torchvision
.venv/bin/pip install -r requirements.txt
```

2. 复现官方输出指标

```
PYTHONPATH=. .venv/bin/python scripts/evaluate_udpr_baseline.py \
--root Dataset \
--section all \
--stage all \
--output results/udpr_official_baseline.json
```

只评估一个子集和阶段：

```
PYTHONPATH=. .venv/bin/python scripts/evaluate_udpr_baseline.py \
--root Dataset --section 3.2.3 --stage 2
```

3. 加载数据和标定

```
from fringe_repair.udpr_io import OfficialUDPRDataset

dataset = OfficialUDPRDataset(
    "Dataset",
    section="3.2.1",
    stage=1,
    include_output=True,
)

sample = dataset[0]
calibration = dataset.calibration("leftcamera_rightcamera")
lower, upper = dataset.fringe_order_bounds("left")

print(sample["fringe_left"].shape)      # torch.Size([480, 640])
print(calibration.camera_matrix_1.shape) # (3, 3)
```

4. 运行测试

```
PYTHONPATH=. .venv/bin/pytest -q
```

若本地没有官方 Dataset/，依赖真实数据的测试会自动跳过。

后续实验

计划对比 WFT/TPR、原始 UCNNet、连续条纹级回归、序数条纹级模型、完整 置信度方法和 Adapter 测试时自适应。主要评价指标包括：

- 相位 MAE、RMSE、Bad-0.1、Bad-0.2 和 Bad-0.5；
- 条纹级准确率、 2π 跳变率及不确定度校准；
- 边缘、弱纹理、暗区和饱和区的分区域误差；
- 单场景优化迭代数、耗时、参数量和显存；
- 标定三角测量后的三维 RMSE 与 Chamfer Distance。

关键消融：

消融设置	验证目标
连续回归 → 序数概率推断	条纹级表示
去掉条纹级熵	不确定度作用
直接绝对相位 → 有界残差	相位细化方式
固定权重 → 置信度加权	鲁棒物理损失

消融设置	验证目标
随机初始化 → 共享初始化	收敛速度
全参数优化 → Adapter	计算效率

当前边界

- 尚未完整重新训练原论文 UCNNet，当前 Baseline 数值来自官方保存输出；
- 创新网络已完成前向结构，置信度物理损失、训练入口和 Adapter 尚未完成；
- 当前结果证明数据及评价链路正确，不能据此宣称创新方法优于 Baseline；
- 官方公开场景数量有限，后续实验必须避免跨场景数据泄漏；
- 三维精度需要使用真实标定进行三角测量，不能用相位线性缩放代理毫米误差。

辅助四步条纹修复模块

仓库仍保留早期四步相移条纹破损实验代码，包括合成退化、传统修复、U-Net/Pix2Pix 和物理双头网络。该模块使用统一 NPZ 格式：

```
fringe [4,H,W], phase [H,W], depth [H,W], valid [H,W]
```

它用于辅助验证相位损失和代码组件，不属于当前 UDPR 官方数据的主实验协议，也不能把单帧/双目数据重新解释成四步相移序列。相关入口为 `train.py`、`test.py` 和 `scripts/make_synthetic.py`。

引用与致谢

本项目基于以下工作开展：

H. Yu, X. Chen, R. Huang, et al., “Untrained deep learning-based phase retrieval for fringe projection profilometry,” *Optics and Lasers in Engineering*, vol. 164, 107483, 2023.

如本项目对你的研究有帮助，请同时引用原始 UDPR/UCNNet 论文及其官方数据。